모델링 및 배포

• 모델 로드 및 설정

```
def load_model(
             self, model_id, model_config, quantize_config: Optional[QuantizeArgs] = None
             model = AutoModelForCausalLM.from_pretrained(
                                                         모델을 로드하고 양자화
                 model id,
                 torch dtype=model config.torch dtype,
                 low cpu mem usage=True,
                 use cache=False,
42
                 device map=0,
                 max_length=model_config.max_length,
                 quantization_config=quantize_config,
             model.gradient checkpointing enable()
             model.enable_input_require_grads()
             model.is parallelizable = False
             model.model parallel = False
                 model = prepare_model_for_kbit_training(model)
                                                              메모리 최적화
             return model
             def get_lora_target(self, lora_target_config):
                 return lora target config.targets
71
             def get_lora_config(self, lora_config, lora_targets: List):
72
                 tora_contig = Loracontig(
                      task type=TaskType.CAUSAL LM,
                                                             LoRA 설정 정의
75
                      inference_mode=False,
                      r=lora config.r,
77
                      lora_alpha=lora_config.alpha,
                      lora dropout=lora config.dropout,
79
                      target_modules=lora_targets,
                     bias="none",
80
                 return lora_config
```

• Custom 모델 학습

```
def get_train_args(self, train_args):
                                             훈련에 사용할 파라미터 정의
             args = TrainingArguments(
                 run_name=train_args.run_name,
94
                 logging steps=train a---
                                                   def get_trainer( □ 메서드를 호출해 학습
                 num train epochs=trai
                                                        self,
                per_device_train_batc 114
96
                per device eval batch 115
                                                        model,
                 gradient accumulation 116
                                                        tokenizer,
98
                dataloader num worker 117
                                                        train args,
                 learning_rate=train_a
100
                                                        train_dataset,
101
                 weight_decay=train_ar
                                                        eval dataset,
102
                 warmup_ratio=train_ar
                                                        callbacks,
                 lr scheduler type=tra
103
                                                        data_collator,
                 save steps=train args
104
                                                   ):
                 eval steps=train args
105
                fp16=train args.fp16, 123
                                                        trainer = Trainer(
106
                eval_strategy=train_a 124
                                                            model=model.
107
                 remove_unused_columns 125
108
                                                             tokenizer=tokenizer,
                 report_to=train_args.
109
                                                            args=train_args,
                                    126
110
                                    127
                                                            train_dataset=train_dataset,
             return args
                                                            eval_dataset=eval_dataset,
                                    128
                                                            callbacks=callbacks,
                                    129
                                                            data_collator=data_collator,
                                    130
                                    131
                                    132
                                                        return trainer
```

모델링 및 배포

• 학습된 모델 저장 및 배포

```
def train(self, trainer):
134
                trainer.train() 학습 완료된 모델 경로에 저장
135
136
           def save_model(self, model, save_path):
137
               model.save_pretrained(save_path, from_pt=True)
138
139
           def model to huggingface(self, model, model id):
140
141
               model.push_to_hub(model_id)
142
            def tokenizer_to_huggingface(self, tokenizer, model_id):
143
                tokenizer.push_to_hub(model_id)
144
```

Huggingface Hub에 모델과 토크나이저를 업로드 하고 경로에 배포 다른 사용자도 Hub에서 Custom한 모델을 다운로드해서 사용 할 수 있음